

Report of Air Pollution Forecasting - LSTM Multivariate

Yansong He
2830791284@qq.com

Abstract

本研究利用长短期记忆网络（LSTM）对多变量空气污染数据进行预测，旨在准确预测PM2.5浓度。研究使用了一个五年内的小时级天气与污染水平数据集，数据包括日期时间、PM2.5浓度、露点、温度、压力、风向、风速及降水情况等特征。通过数据预处理，计算特征相关性并选择高相关性变量以构建模型输入，最终生成序列数据用于训练LSTM模型。模型经过50轮训练，使用Adam优化器和均方误差（MSE）作为损失函数。模型评估结果显示，预测值与真实值呈现出良好的趋势相符，平均绝对误差（MAE）为12.63，表明该模型在空气质量预测任务中的有效性和实用性，为进一步的环境监测和决策支持提供了基础。

Introduction

空气污染已成为全球面临的重大环境问题，对人类健康和生态系统造成了深远影响。准确预测空气污染水平，尤其是PM2.5浓度，对于有效实施环境管理政策和保护公众健康至关重要。近年来，随着深度学习技术的发展，长短期记忆网络（LSTM）作为一种处理时序数据的有效工具，在空气质量预测领域得到了广泛应用。

LSTM网络通过其独特的结构，克服了传统递归神经网络（RNN）在处理长序列时的短期记忆问题，能够有效捕捉到长期依赖关系。而在多变量时间序列预测中，LSTM能够同时处理多种气象因素对PM2.5浓度的影响，提供更为准确的预测结果。本研究的目标是构建并评估LSTM模型，通过有效利用历史污染和天气数据，预测未来的PM2.5水平。

本报告的结构如下：部分将概述LSTM模型的基本原理；随后介绍研究中使用的数据集及预处理方法；接着详细描述模型的构建与训练过程；最后，对模型的预测结果进行分析与讨论。通过该研究，期望为环境管理提供科学依据，并为未来进一步的研究打下基础。



Models: LSTM

1. 长短期记忆网络:

- 定义:** LSTM是一种特殊类型的RNN，旨在克服传统RNN在处理长序列时的短期记忆问题。它能够有效地捕捉和学习长期依赖关系。
- 动机:** 传统RNN在处理长序列时容易遇到梯度消失或爆炸的问题，这使得模型难以保留早期输入的信息。LSTM引入了一种新的结构来保留和更新信息，有效解决这些问题。

2. LSTM的基本结构:

LSTM单元包括三个主要的门控机制：**输入门**、**遗忘门**和**输出门**，这些门控单元控制信息的流入、存储和输出。LSTM的关键是单元状态，它就像一个传送带，在序列中保持信息的流动，只有少量的线性交互。这样使得信息可以高效地在序列中流动。



(1) 遗忘门 (Forget Gate)

- **功能：** 决定上一单元状态中哪些信息应该被遗忘。
- **公式：** $f_t = \sigma(W_f \cdot [h_{t-1}, X_t] + b_f)$

其中：

- f_t 是遗忘门的输出。
- W_f 是权重矩阵, b_f 是偏置。
- h_{t-1} 是上一时间步的隐藏状态。
- X_t 是当前时间步的输入。

(2) 输入门 (Input Gate)

- **功能:** 确定当前时间步的输入中哪些值将被存储到单元状态中。
- **公式:** $i_t = \sigma(W_i \cdot [h_{t-1}, X_t] + b_i)$ 这里, i_t 表示输入门的输出。

(3) 输出门 (Output Gate)

- **功能:** 决定当前单元状态中哪些信息将被输出。
- **公式:** $o_t = \sigma(W_o \cdot [h_{t-1}, X_t] + b_o)$ 其中, o_t 是输出门的输出。

(4) 单元状态的更新

LSTM具有专门的单元状态 C_t , 负责存储信息并进行更新。更新过程包括以下几步:

- **计算候选单元状态**

候选值: 首先, 生成当前输入的候选值 $\tilde{C}_t$, 通过tanh激活函数生成:

$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, X_t] + b_c)$$

- **更新单元状态**

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t$$

- C_{t-1} 是前一时间步的单元状态。
- f_t 控制从前一状态中遗忘多少信息。
- i_t 控制从当前输入中添加多少新信息。

(5) 计算输出

- **输出状态:** 最后, LSTM的输出状态 h_t 由**当前单元状态**和**输出门**的控制决定: $h_t = o_t \cdot \tanh(C_t)$

3. Evolution and Usage of LSTMs:

- **训练复杂性:**
 - LSTM的训练相较于传统的RNN更为复杂, 但在处理长序列问题上表现更佳。
- **多种应用:**
 - LSTM被广泛用于各种任务, 包括文本生成、机器翻译、语音识别、视频预测和时间序列分析。
- **单向和双向LSTM:**
 - **单向LSTM**只考虑过去的信息, 而**双向LSTM**可以同时考虑过去和未来的信息, 这在语音识别和自然语言处理等任务中特别有效。

Experimental Studies

1. 问题描述:

问题提供了一个报告五年内每小时天气和污染水平的数据集, 数据包括日期时间、PM2.5 浓度以及露点、温度、压力、风向、风速和雨雪累积小时数的天气信息。使用这些数据来构建一个预测问题, 即根据前几个小时的天气状况和污染情况, 预测下一个小时的污染情况。

原始数据中的完整特征列表如下:


- `No` : row number
- `year` : year of data in this row
- `month` : month of data in this row
- `day` : day of data in this row
- `hour` : hour of data in this row
- `pm2.5` : PM2.5 concentration
- `DEWP` : Dew Point
- `TEMP` : Temperature
- `PRES` : Pressure
- `cbwd` : Combined wind direction
- `IWS` : Cumulated wind speed
- `IS` : Cumulated hours of snow
- `Ir` : Cumulated hours of rain

2. 数据预处理:

读取文件, 创建date变量, 编码类型变量 (例如 *cbwd*) , 处理表格中的缺失值, 并输出特征相关性热图, 代码及结果如下:

```
# 计算特征的相关性矩阵
correlation_matrix = data.corr()

# 输出相关性热图
plt.figure(figsize=(12, 8))
sns.heatmap(correlation_matrix, annot=True, fmt=".2f", cmap='coolwarm', square=True)
plt.title('特征相关性热图', fontsize=16)
plt.show()
```



选择相关性强的变量进行模型训练，设定阈值 $threshold = 0.04$ ，将相关性弱的变量筛选，此处筛选了变量 I_s ，并将剩下的变量组成新的数据集并进行归一化处理，代码如下：

```
# 选择与 PM2.5 相关性高的特征
threshold = 0.04 # 选择相关性阈值
correlation_with_target = correlation_matrix['pollution']
selected_features = correlation_with_target[abs(correlation_with_target) >
threshold].index.tolist()
selected_features.remove('pollution') # 移除目标特征本身

# 使用选择的特征生成新的数据集
data_selected = data[['pollution'] + selected_features] # 保证包含目标列

# 归一化
scaler = MinMaxScaler()
scaled_data_selected = scaler.fit_transform(data_selected)
```

从经过归一化的特征数据中生成序列，采用过去 24 小时的特征信息作为输入，将当前时刻的污染值作为预测目标。随后，将生成的序列数据按 80% 的比例分割为训练集和测试集，以支持模型的训练与评估。此过程使得模型能够通过历史数据学习潜在模式，并对未来的污染水平进行有效预测，从而为空气质量监测提供了坚实的基础，代码如下：

```
# 3. 创建序列数据
def create_sequences(data, seq_length=24):
    xs = []
    ys = []
    for i in range(len(data) - seq_length - 1):
        x = data[i:i + seq_length]
        y = data[i + seq_length, 0] # pollution作为预测目标
        xs.append(x)
        ys.append(y)
    return np.array(xs), np.array(ys)

seq_length = 24 # 以过去24小时预测
x, y = create_sequences(scaled_data_selected, seq_length)

# 分割训练集和测试集
split_idx = int(0.8 * len(x))
x_train, x_test = x[:split_idx], x[split_idx:]
y_train, y_test = y[:split_idx], y[split_idx:]
```

3. 模型构建与训练:


模型架构采用了 `Sequential` 模型，首先定义了输入形状以匹配时间序列的特征。接着，添加了三层 LSTM 单元，其中前两层使用 `return_sequences=True` 参数，以便允许进一步的层叠。为了降低过拟合的风险，在每一层 LSTM 后面均添加了 Dropout 层。最后，使用全连接层（`Dense`）输出一个单一的预测值，代码如下：

```
# 4. 构建LSTM模型
model = Sequential()
model.add(Input(shape=(seq_length, x.shape[2]))) # 使用 LSTM 需要的输入形状
model.add(LSTM(100, return_sequences=True))
model.add(Dropout(0.3)) # 增加 Dropout 以降低过拟合风险
model.add(LSTM(50, return_sequences=True)) # 使用return_sequences=True，以便可以叠加更多的LSTM层
model.add(Dropout(0.3)) # 增加 Dropout
model.add(LSTM(25)) # 第三层 LSTM
model.add(Dropout(0.3)) # 增加 Dropout
model.add(Dense(1)) # 预测值应为单个数
```

在模型编译过程中，设置了学习率为 0.001，并选择 Adam 优化器和均方误差（MSE）作为损失函数。设定训练参数 `epochs=50`，`batch_size=32`，经过 50 轮的训练，模型利用训练集数据进行优化，同时在验证集上进行评估，以监测其泛化能力。最终，使用测试集数据对模型进行了预测。这一模型设计和训练过程为未来的污染水平预测奠定了基础。


4. 模型预测结果:

- 预测结果与真实值比对：




模型的预测结果与真实值之间的比较显示出了一定的准确性。绘制的预测值与真实值的曲线图表明，模型能够有效地捕捉到污染水平的变化趋势。整体趋势上，预测的 PM2.5 浓度与实际值存在较好的对应关系，特别是在高浓度的污染时段，模型的预测能够较为准确地反映出实际的变化。这表明模型在捕捉时间序列数据的动态变化的能力上表现良好。

- 训练损失和验证损失曲线：




从训练损失和验证损失曲线的趋势来看，训练损失逐渐下降并趋于平稳，而验证损失同样展现了相似的趋势。这一现象表明模型并未出现严重的过拟合现象。通过比较训练集和测试集的损失，验证了模型的良好泛化能力，能够在未见数据上稳定地进行预测。

● 预测值与真实值散点图：



对于预测误差的分析，通过散点图进行的展示，真实值与预测值之间的关系进一步体现了模型性能的可靠性。散点图中的数据点大多数集中在 45 度参考线附近，表明模型的预测值与真实值的契合度较高。这意味着，模型在大多数情况下能够准确地反映实际的 PM2.5 浓度变化。

● 预测误差的直方图：



● 性能指标：

平均绝对误差 (MAE): 12.63

综合上述分析结果, LSTM 模型在 PM2.5 浓度的预测中展现出了良好的性能, 能够有效地捕捉和分析时间序列数据。尽管存在一定的预测误差, 但整体趋势的把握及较高的相似度表明, 该模型在空气质量监测和预警系统中具备实际应用的潜力。未来的研究可以考虑进一步优化模型结构、参数调节, 加入更多的外部因素, 以提升预测的准确性和稳定性, 从而更好地为环境治理和公共健康提供科学依据。